深度学习概览
及其在语音处理中的应用

机器学习讨论班

毛思成

2026/6/16



大纲

1. 机器学习概览
2. 深度学习基本概念
3. 经典架构
4. 从 Transformer 到 GPT
5. 从文本到多模态
6. 深度学习时代的语音处理
7. 感想

机器学习概览

- 基本概念
- 模式识别
- 特征
- 表征
- 表征学习
- 什么是好的表征?
- 数据与标签
- 小节

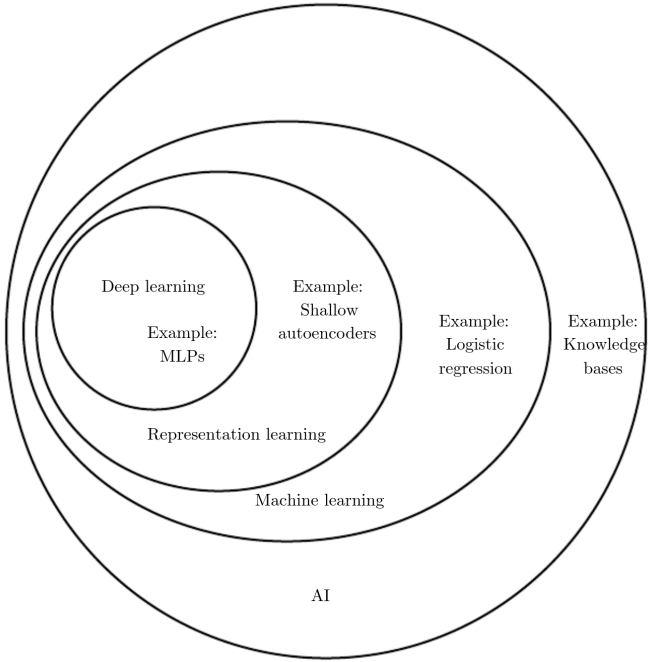
基本概念

机器学习：借助算法从数据中获得统计规律，并利用规律对未知数据进行预测。

深度学习：专指以人工神经网络为主要模型的机器学习算法

算法 = 模型 + 训练 + 推理

- 模型 model：一种独立于数据的先验结构
- 训练 training：调整模型参数拟合已知数据的过程
- 推理 inference：固定模型参数预测未知数据的过程



模式识别

Pattern Recognition

机器学习的经典任务是模式识别，其核心在于判断**是**与**不是**，即**什么属于同一模式，什么不属于同一模式**。

例如经典的手写数字识别问题（MNIST， Lecun）



难点：

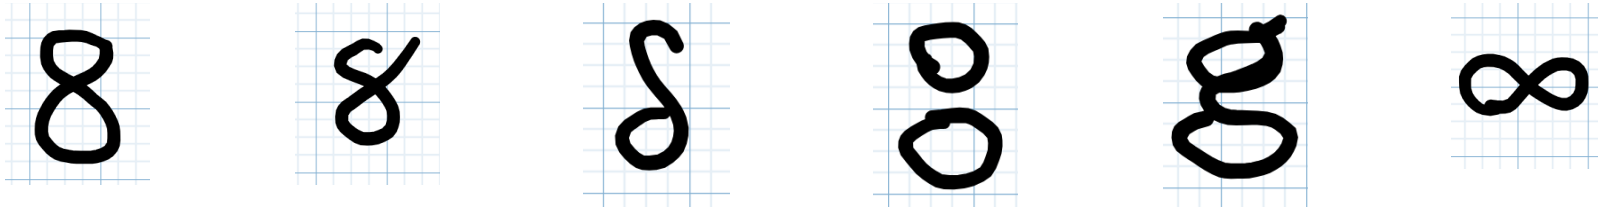
- 概念上**不同**的数字在像素空间中的实现**不同**（信号意义上的差异）
- 概念上**相同**的数字在像素空间中的实现**也不同**（噪声意义上的差异）
- 这两种差异在像素空间中的区别并不清晰（低信噪比）

由此使用统计模型，因其能够容忍噪声，在含有噪声的情况下进行推断。

特征

Feature

模式识别起决定性作用的因素。例如：8 的特征是什么？



- 人眼很容易判断，但判断的依据很难用自然语言完整叙述
- Moravec 悖论：人类所独有的高阶智慧能力只需要非常少的计算能力，例如推理，但是无意识的技能和直觉却需要极大的运算能力。（所谓的高阶能力实际上是符号能力，而无意识的技能是前符号/符号化的能力。）
- 关键问题：应该如何表示这些特征使得机器能够识别相应的模式？

表征

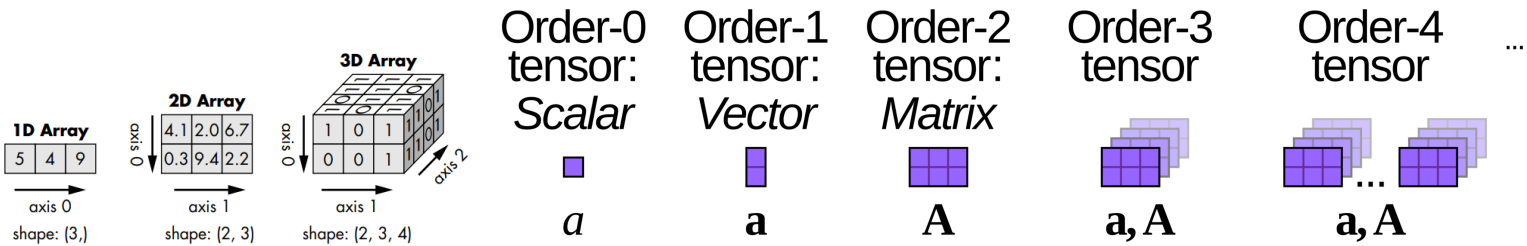
Representation

常见信号的（原始）表征

- 文本表征为时间序列： $x \in V^N$，其中 V 为字典， N 为离散时间。
- 图片表征为像素空间中的点： $x \in \mathbb{R}^{W \times H \times C}$，其中 W 为宽度，H 为高度，C 为通道数。
- 声音表征为时间序列： $x \in \mathbb{R}^T$，其中 T 为时间。

多维数组 array / 张量 tensor

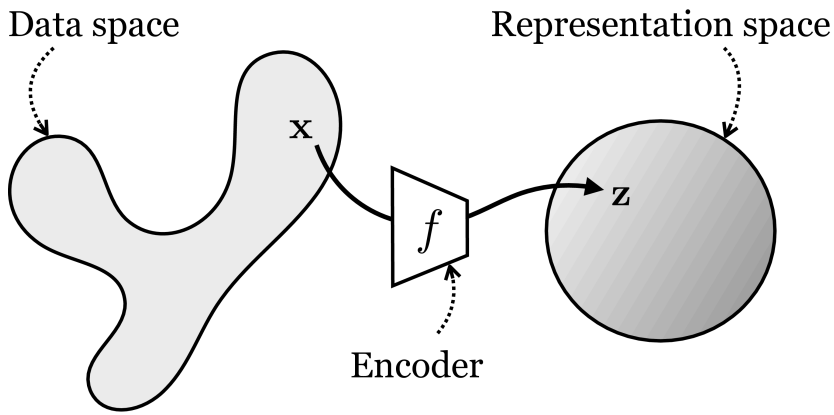
- 把质的差异统一为纯粹的量的差异
- 划分轴仅仅是为了方便操作



表征学习

Representation learning

由于前面提到的信噪比问题，我们希望找到一个映射 $f: x \mapsto z$ 使得原数据 $x \in X$ 的表征 $z \in Z$ 具有**更好**的性质。这个任务被称为表征学习。

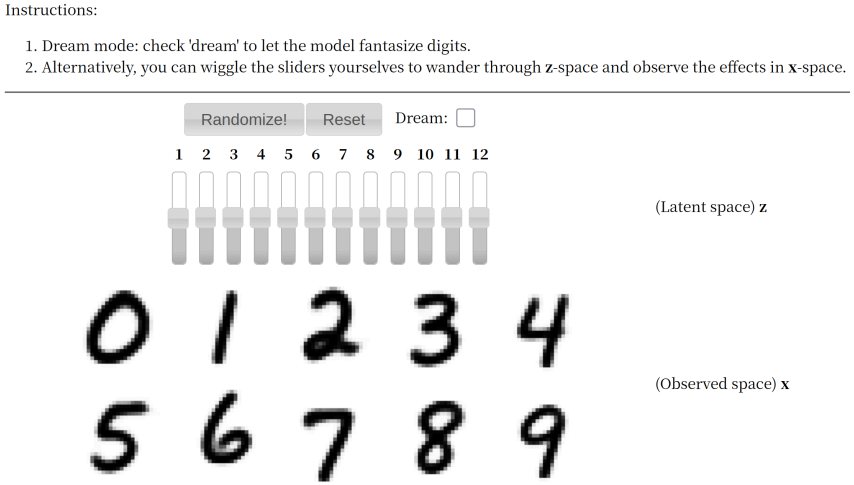


根据语境的不同，这里的映射 f 也被称为编码器 encoder，Z 所在的空间被称为隐空间 latent space， X, Z 也被称为流形 manifold，z 也被称为嵌入 embedding 或者编码 code。

什么是好的表征？

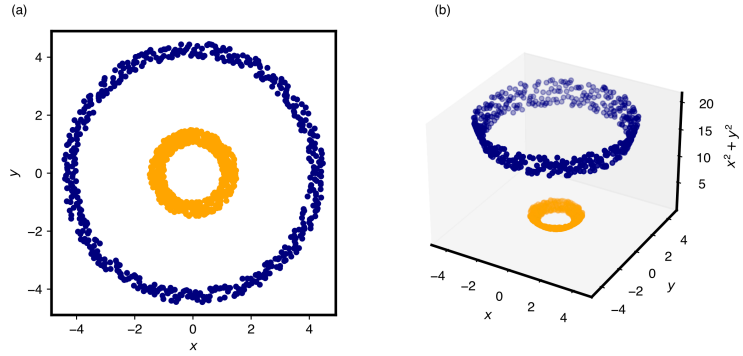
信噪比高（压缩率高）

MNIST 图像表征从原空间 $\mathbb{R}^{28\times28\times1}$ 映射到隐空间 $\mathbb{R}^{12}$



（线性）可分性强

甜甜圈式二分类数据从原空间 $\mathbb{R}^3$ 映射到隐空间 $\mathbb{R}^3$



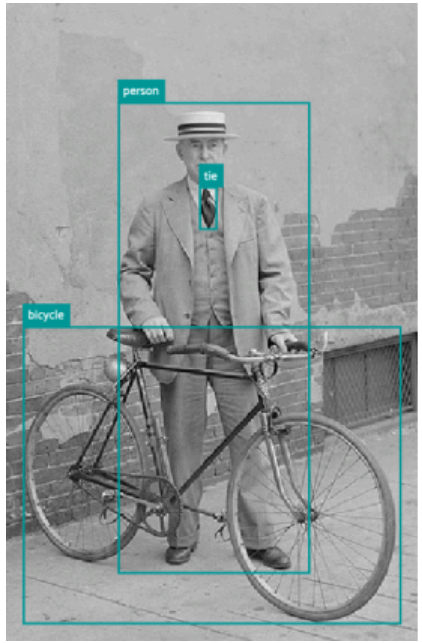
数据与标签

数据常有：文本（网页、出版物），音频（播客、视频音轨），图像（照片、图画、截图）。

但标签不常有（电影影评打分）。标签因任务而异，多数情况靠人工打标。

学习数据是否自带标签？监督学习 vs 无监督学习

在无标数据集上如何巧妙的**构造**标签，决定了是否能够利用海量数据。一种新的构造方式设定了一种新的模式识别任务，这种人为构造的任务能够帮助真实任务。





小结

机器学习的基本假设：

1. 统计分布假设：数据集 $\mathcal{X}$ 总是服从于表征空间 X 上的一个（未知的）数据分布 $p_{\mathcal{X}}$。数据点可以看成分布的独立同分布采样 sample/实现 realization $x_1, \ldots, x_n \overset{i.i.d.}{\sim} p_{\mathcal{X}}$，且这个分布一般默认存在密度函数。
2. 流形假设：存在一个好的表征映射，使得数据点可以嵌入到一个低维流形。

机器学习的目标：

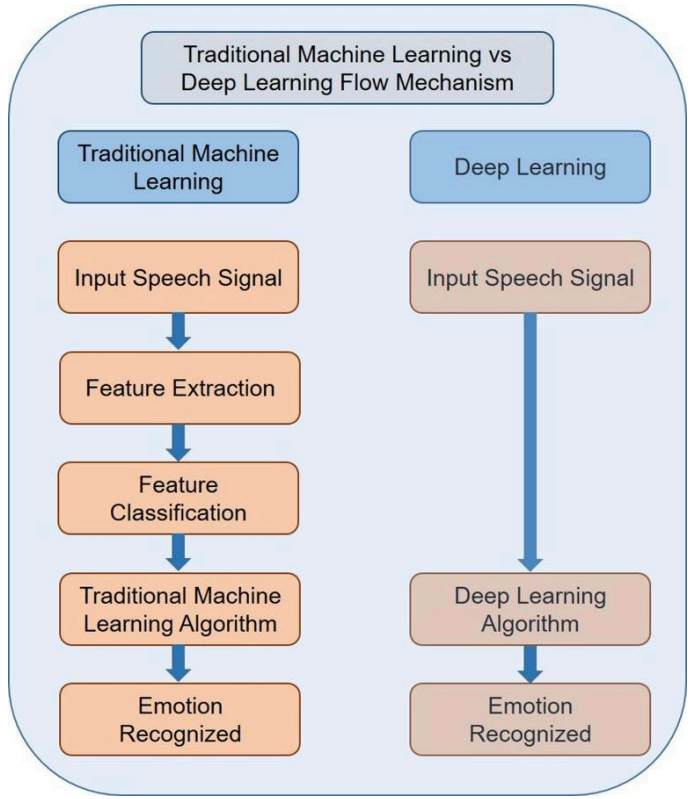
1. 密度估计（生成式任务）：根据数据集估计分布，以便可以采样出**与数据集一致**的新数据。
2. 模式识别（判别式任务）： 根据带标签的数据集 $(x, y) \in X \times Y$，求后验分布 $p(y|x)$。
3. 表征学习：找到映射 $f : X \to Z$，使得变换后的表征空间 Z 上的分布 p_Z 有更简单的形式。它使得生成式任务的采样更容易，使得判别式任务的决策更容易。

深度学习基本概念

- 深度学习的特点
- 模型：人工神经网络
- 推理和训练
- 梯度优化器
- 正向传播和反向传播

深度学习的特点

1. 匀质化：
   - 硬件：重复的简单计算单元。
   - 模型：重复的结构相似的神经网络层。
   - 训练和推理：统一的计算过程，与模型解耦。
   - 数据：统一的张量表示不同模态的数据。
   - 任务：统一的计算处理不同任务。
2. 规模化：
   - 模型规模化
   - 数据规模化
3. 端到端：传统机器学习流程中异质性的处理步骤不断被整合进匀质的神经网络计算。



模型：人工神经网络

- 感知机 perceptron (Rosenblatt,1958)：用线性变换加上一个非线性激活（例如 sigmoid, tanh, ReLU）

$$f_\theta(x) = \sigma(w^\top x + b)$$

  模拟生物神经细胞对刺激的响应。（异或问题）

- 多层感知机 multilayer perceptron (Rumelhart,1987)：堆叠多层感知机

$$f_\theta(x) = \sigma^{(L)}(W^{(L)}\sigma^{(L-1)}(\cdots\sigma^{(1)}(W^{(1)}x + b^{(1)})\cdots) + b^{(L)})$$

  并提出相应的反向传播算法，解决了异或问题。（通用逼近定理）

- 现代神经网络的基础模块：CNN(1998)，RNN/LSTM(1997)，ResNet(2015)，Attention(2014), Transformer(2017)

推理和训练

- 训练：给定带标签数据集 $\mathcal{X} = \{(x_i, y_i)\}_{i=1}^{N}$，含参神经网络 f_θ，损失函数 $\ell(\cdot, \cdot)$，优化参数 θ

总体误差：

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \ell(f_\theta(x_i), y_i)$$

目标：

$$\hat{\theta} = \arg\min_{\theta} \mathcal{L}(\theta)$$

- 推理：给定任意数据 x，预测其标签 $\hat{y} = f_{\hat{\theta}}(x)$。

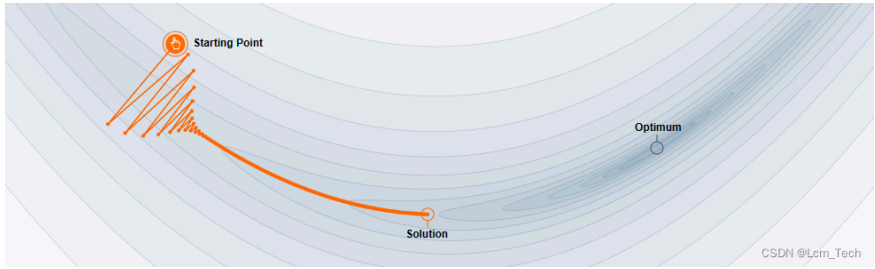
梯度优化器

理论上 $\hat{\theta} = \arg\min_\theta \mathcal{L}(\theta)$ 可以转化为 $\nabla_\theta \mathcal{L}(\theta) = 0$ 求驻点，再逐个代入找到最小值。

实际上 $\mathcal{L}$ 高度非线性，梯度方程没有解析解。常采用梯度下降法近似求解：

1. 从一个**好的初始化**参数 $\theta^{(init)}$ 出发
2. 不断迭代 $\theta^{(new)} \leftarrow \theta^{(old)} - \eta \nabla \mathcal{L}(\theta^{(old)})$，$\eta$ 为一个**指定的**学习率。
3. 直至**收敛**。

随机梯度下降：实践中并不会计算总体损失 $\mathcal{L}$，而是一个随机批次的损失 $\mathcal{L}_{\text{mini-batch}}$。

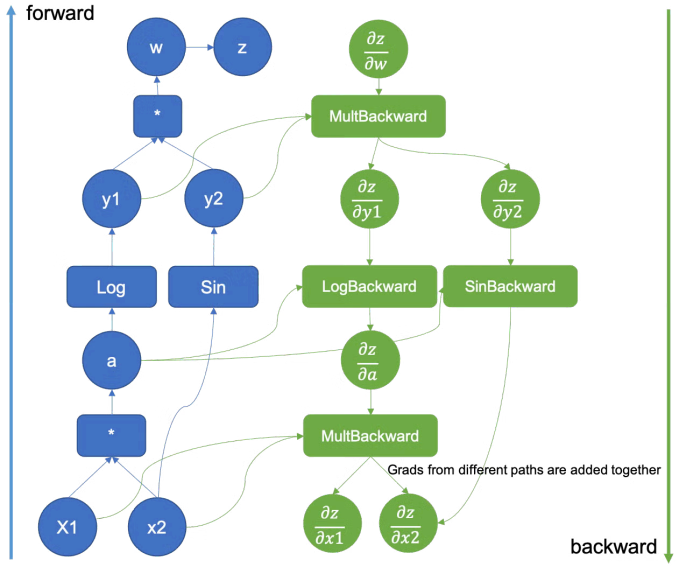


正向传播和反向传播

- 可微映射诱导出切映射

$$f : x \mapsto y \implies df_x : \frac{\partial \mathcal{L}}{\partial y} \mapsto \frac{\partial \mathcal{L}}{\partial x}$$

- 前向传播：可微函数复合链
- 反向传播：导函数乘积链（链式法则）
- 计算图：每个节点（神经元）记录前向传播的激活值和反向传播的梯度值；每条边（神经连接）记录映射/切映射。
- 实现：自动微分引擎是 PyTorch 等深度学习库最核心的部分



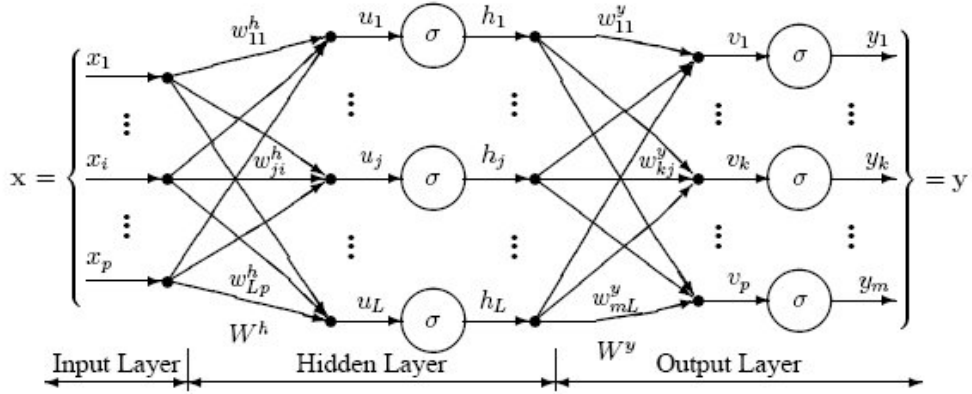
经典架构

- 多层感知机
- 卷积神经网络
- 循环神经网络
- 注意力机制
- 其他
- 小节

多层感知机

Multilayer Peceptron (MLP)，又名前馈 feedforward 网络 ，全连接 fully-connected 网络

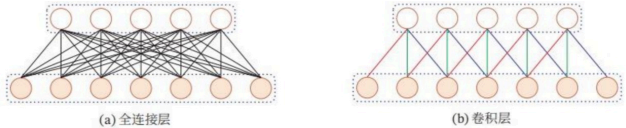
- 生物神经元的最简化模拟
- 线性变换，特征混合
- 全连接，参数量大
- 其他神经网络结构的雏形



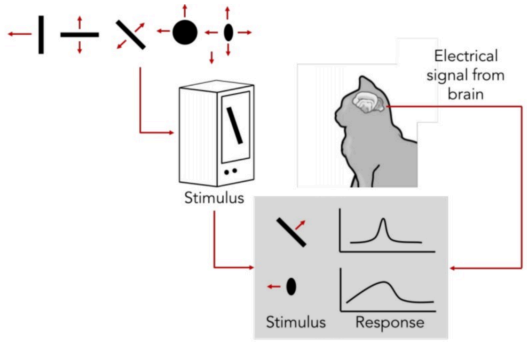
卷积神经网络

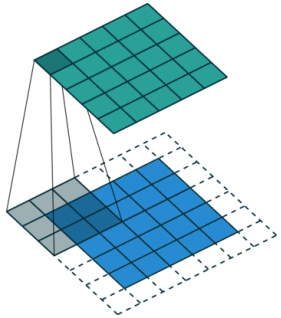
Convolutional neural network (CNN)

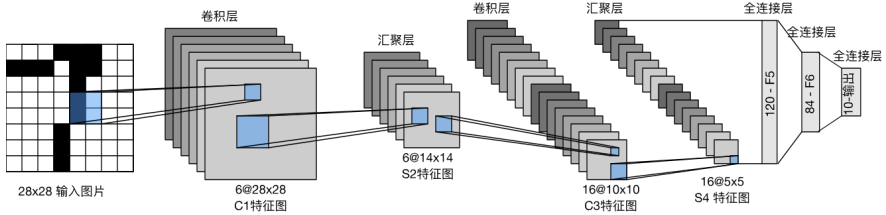
- 受灵长类视觉皮层启发 (Hubel,1961)
- 提取图像特征
- 局部性，平移不变性，权重共享



- 通过降采样实现信息的压缩
- 网络越深，特征图越小，特征越高级



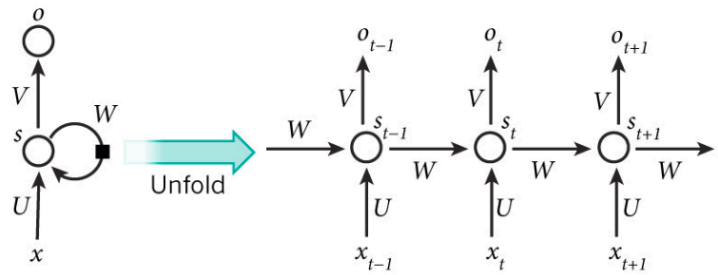


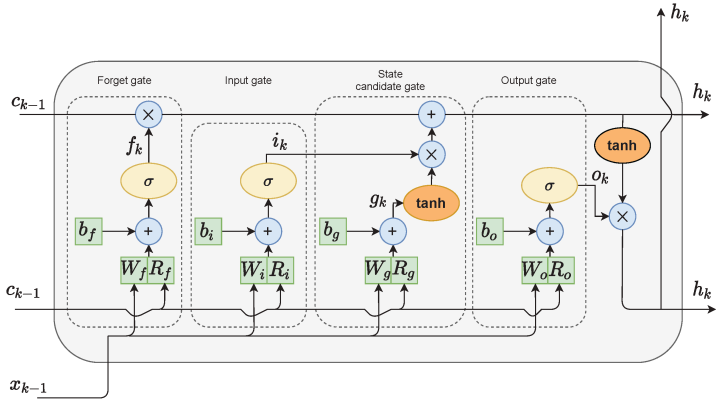


循环神经网络

Recurrent neural network (RNN)

- 自回归结构
- 提取序列特征
- 带门控机制的变体 (LSTM,GRU)





注意力机制

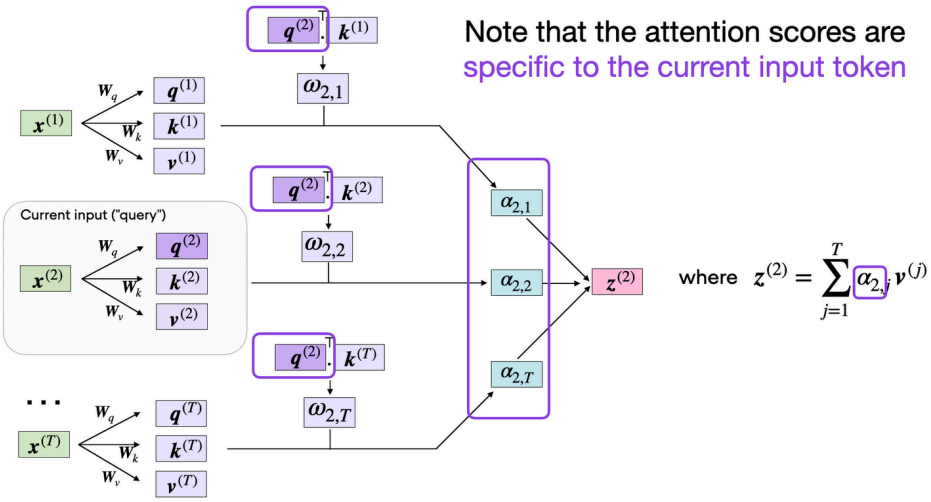
Attention

- 建模序列 $x_{1,\cdots,N}$
- 输入表征 x_i 线性变换得到查询、键、值表征（数据库信息检索范式）
- 注意力=随上下文变化的动态权重

$$q_i = W_q x_i, k_i = W_k x_i, v_i = W_v x_i$$

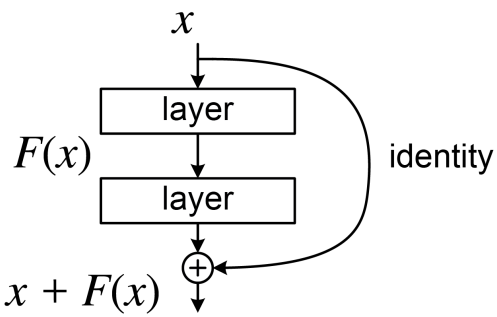
$$o_i = \sum_{j=1}^{N} \frac{\exp(q_i \cdot k_j)}{\sum_{l=1}^{N} \exp(q_i \cdot k_l)} v_j$$

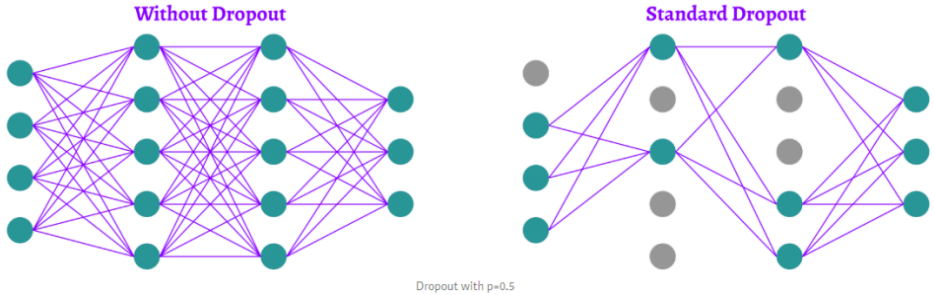
$$o_i = \sum_{j=1}^{N} w_j x_i$$



其他

- 残差连接：解决深层网络训练的梯度传播问题
- 归一化层：解决激活值尺度不稳定的数值问题
- Dropout 层：随机丢弃激活信号，防止过拟合





小结

- 仿生学启发式
- 结构决定知识的性质
- 数值问题、工程技巧

从 Transformer 到 GPT

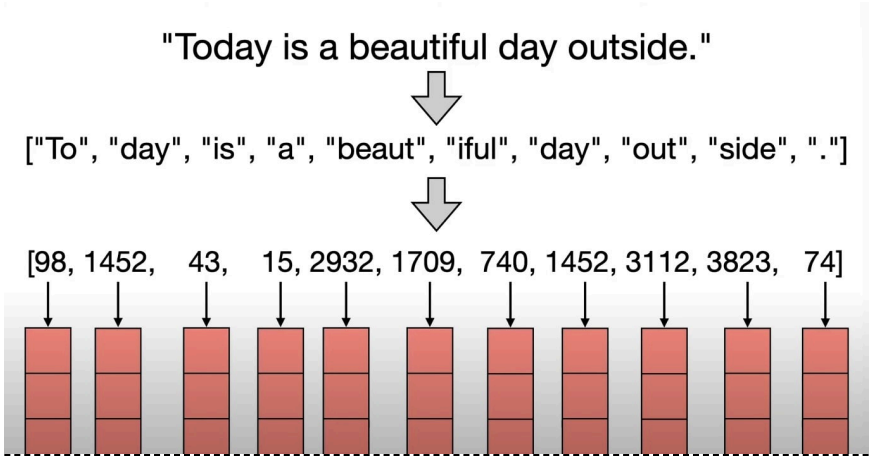
- 从序列到序列
- Transformer
- GPT

从序列到序列

Sequence-to-sequence

- 机器翻译，问答，续写
- 数据：一段文本序列 $X = (x_1, x_2, \cdots, x_n)$
- 标签：另一段文本序列 $Y = (y_1, y_2, \cdots, y_m)$
- 分词器 tokenizer：把文本切分为词元序列的映射
- 码本 codebook：把词元转换为词向量表征
- 从序列到序列的条件自回归建模

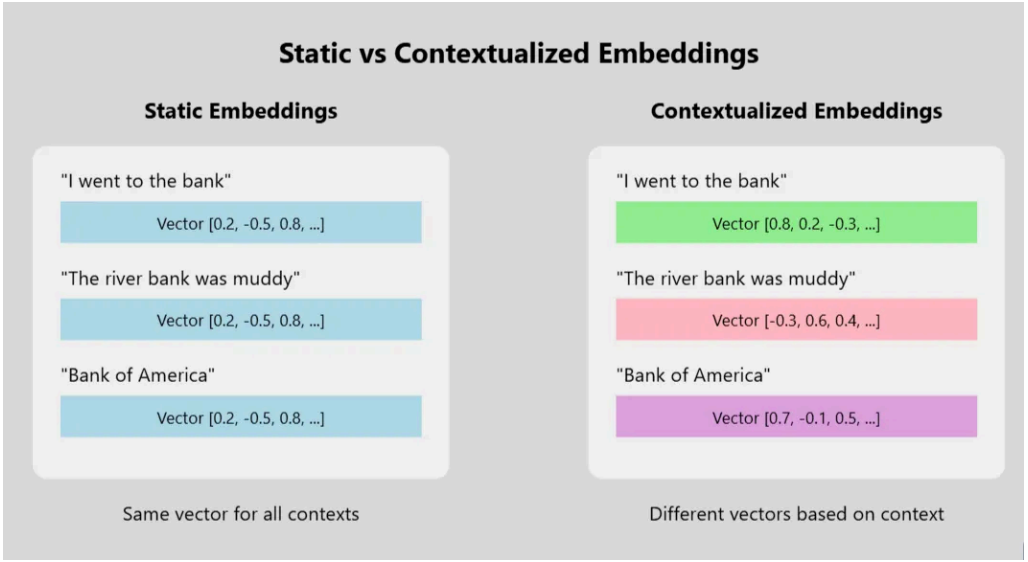
$$P(Y \mid X) = \prod_{t=1}^{m} P(y_t \mid y_{<t}, X)$$



Transformer

- 可并行的自回归序列建模
- 工程优化的结晶
  - 对词向量的上下文建模

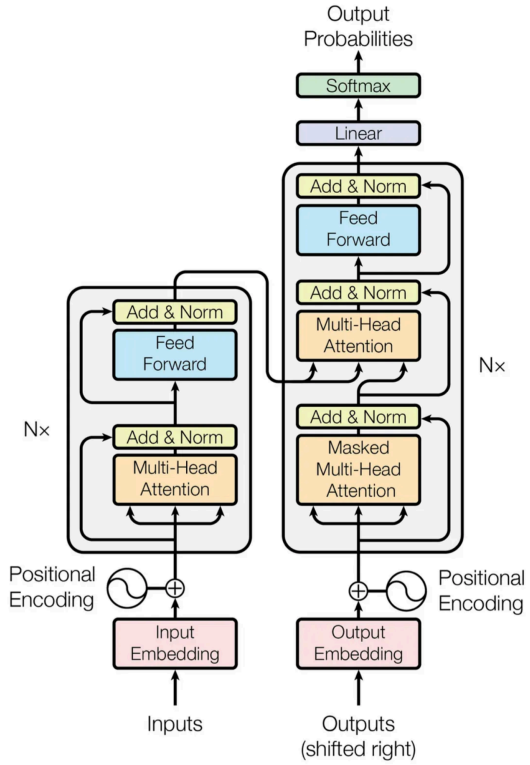
    contextualized embedding
  - 自注意力机制：
    - 全局感受野（vs 卷积神经网络）
    - 可并行计算（vs 循环神经网络）
    - 动态的连接权重（vs 全连接层）
    - 低秩但多头
  - 全连接层：信息混合
  - 残差连接，归一化，Dropout



Transformer

- 可并行的自回归序列建模
- 工程优化的结晶
  - 对词向量的上下文建模

    contextualized embedding
  - 自注意力机制
    - 全局感受野（vs 卷积神经网络）
    - 可并行计算（vs 循环神经网络）
    - 动态的连接权重（vs 全连接层）
    - 低秩但多头
  - 全连接层：信息混合
  - 残差连接，归一化，Dropout

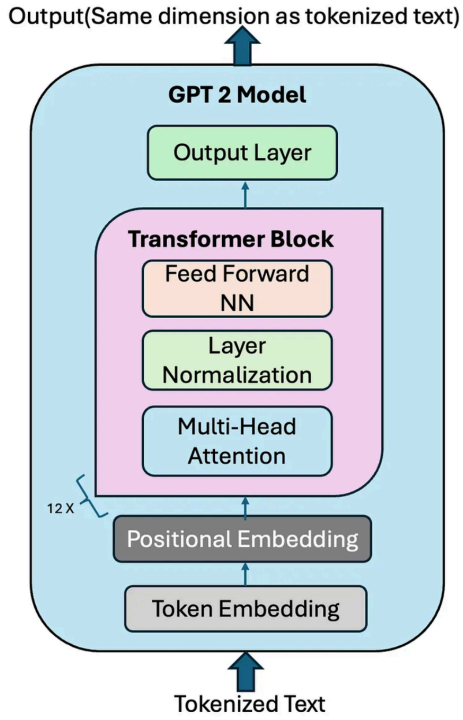


GPT

生成式预训练的 Transformer，Generative Pretrained Transformer

- 构造预训练任务和标签：下一词预测 next-token prediction。
  数据为上文，标签为下一词。
- 微调：将所有文本任务统一为带格式的序列生成任务 (T5)
  如翻译任务：`<English> how are you? <Answer> ça va?`
- 从序列到序列转变成序列生成：纯解码器结构 decoder-only
- 掩码 mask：控制注意力区间在格式标记内
- 指令微调+偏好对齐：基于人类反馈的强化学习 RLHF
- Scale-up：1 亿 < 15 亿 < 1750 亿 < 1 万亿 < ???
- 聊天机器人 (ChatGPT)

```
<Prompt> Translate to French: how are you?
<Assistant> ça va?
```



从文本到多模态

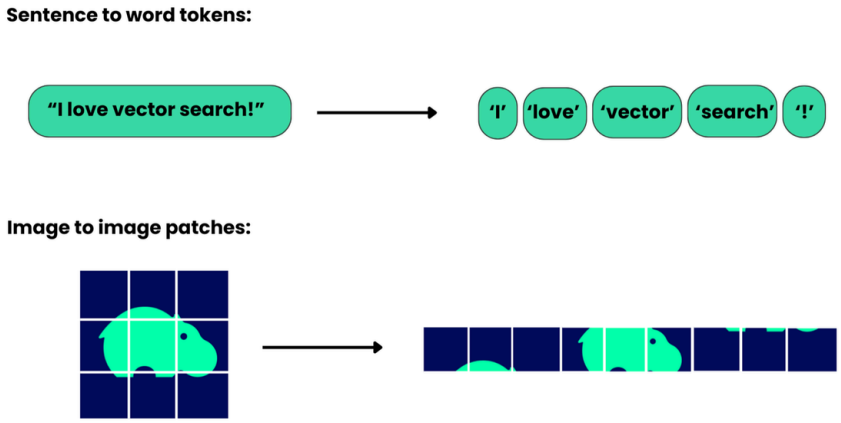
- 一切皆“文本”
- 统一模态空间
- 以语言为中介

一切皆“文本”

Transform everything as text

Transformer 的并行化、规模化能力吸引人们把其他模态的信号都以文本的方式建模。

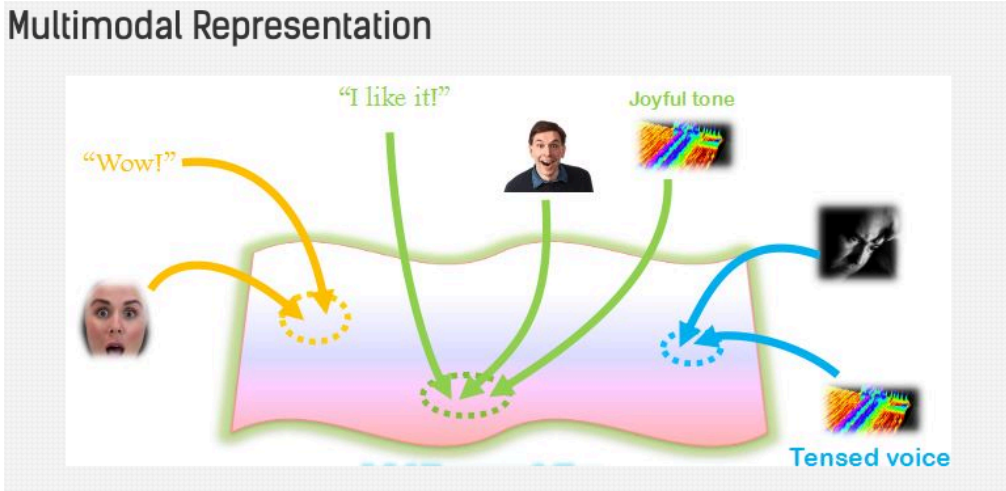
- 文本信号离散且信息率高，图像、声音信号连续且信息率低
- （广义）分词器+编码器：把图像或声音等连续信号压缩成嵌入序列
- 传入 Transformer，其余不变：适用于连续模态到离散模态（文本，类别）的任务
- 如果需要还原回连续模态，需要对应模态的解码器



统一模态空间

多模态任务需要在不同模态间转换

- 图像到文本（图像描述）
- 文本到图像（图像生成）
- 声音到文本（语音识别）
- 文本到声音（语音合成）
- 视频到声音（视频配乐）
- 视频到视频（自动剪辑）
- 等等 …

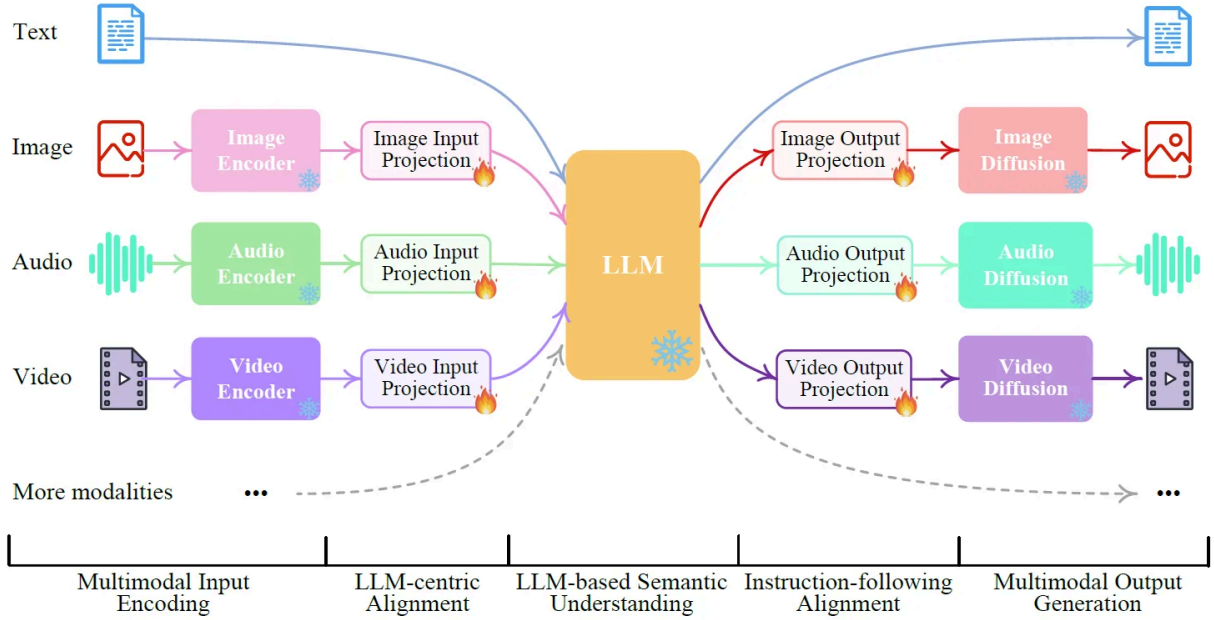


如何保证不同模态嵌入之间的语义一致性

- 对齐：**以文本为锚点**，训练对齐映射使不同模态语义相近的嵌入在统一空间中，使向量距离反映语义距离

任意模态大模型

- 各自模态配备编码器、解码器、对齐映射
- 统一的大语言模型骨干网络建模



深度学习时代的语音处理

- 语音的特殊性
- 传统语音处理
- 判别式任务举例：语音到文本（ASR）
- 生成式任务举例：文本到语音（TTS）

语音的特殊性

信息密度低：

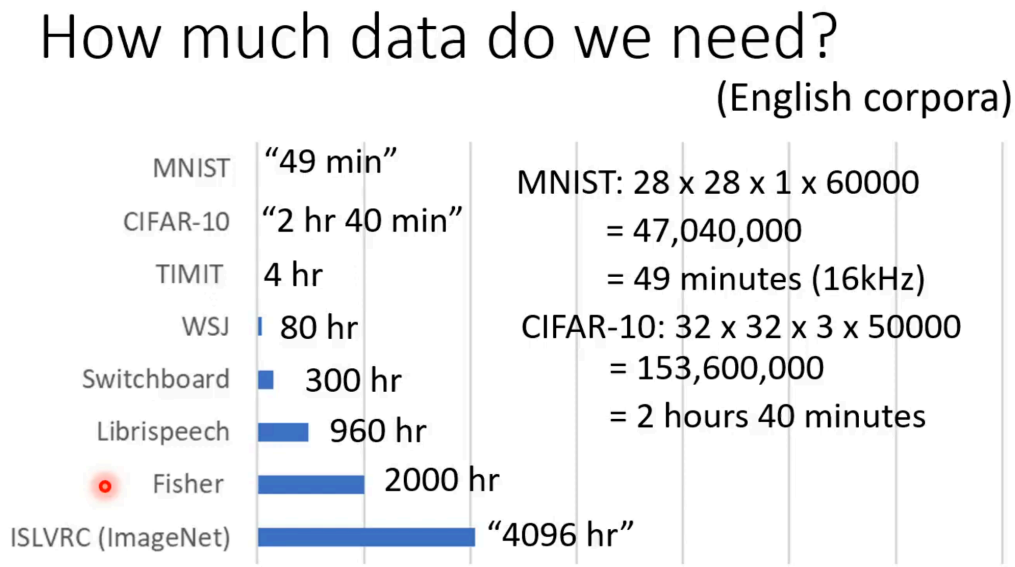
- 3 分钟的音乐波形文件大小

  44100Hz×16bit×2×180s/8≈30.3 MB

  相当于一本千万字小说
- 可用数据少

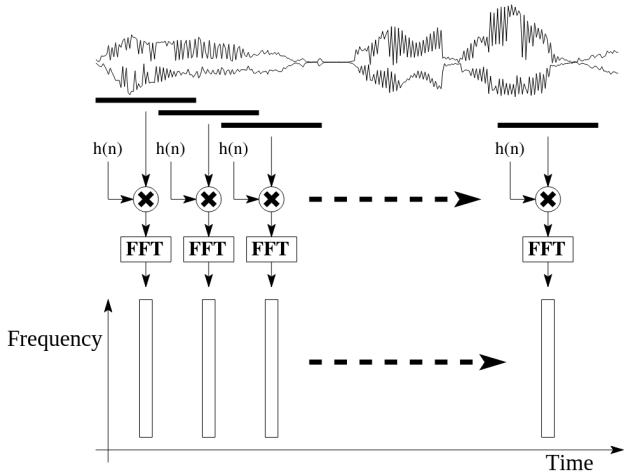
信息层次丰富，多且杂：

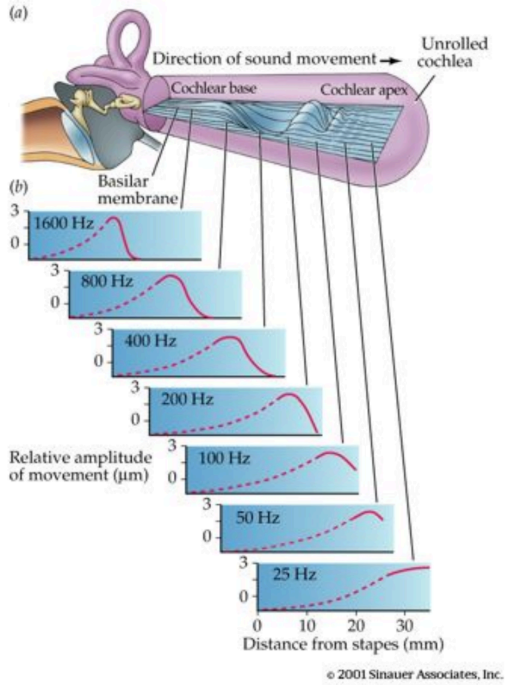
- 音色
- 音素
- 韵律、语气、情绪
- 副语言现象



传统语音处理

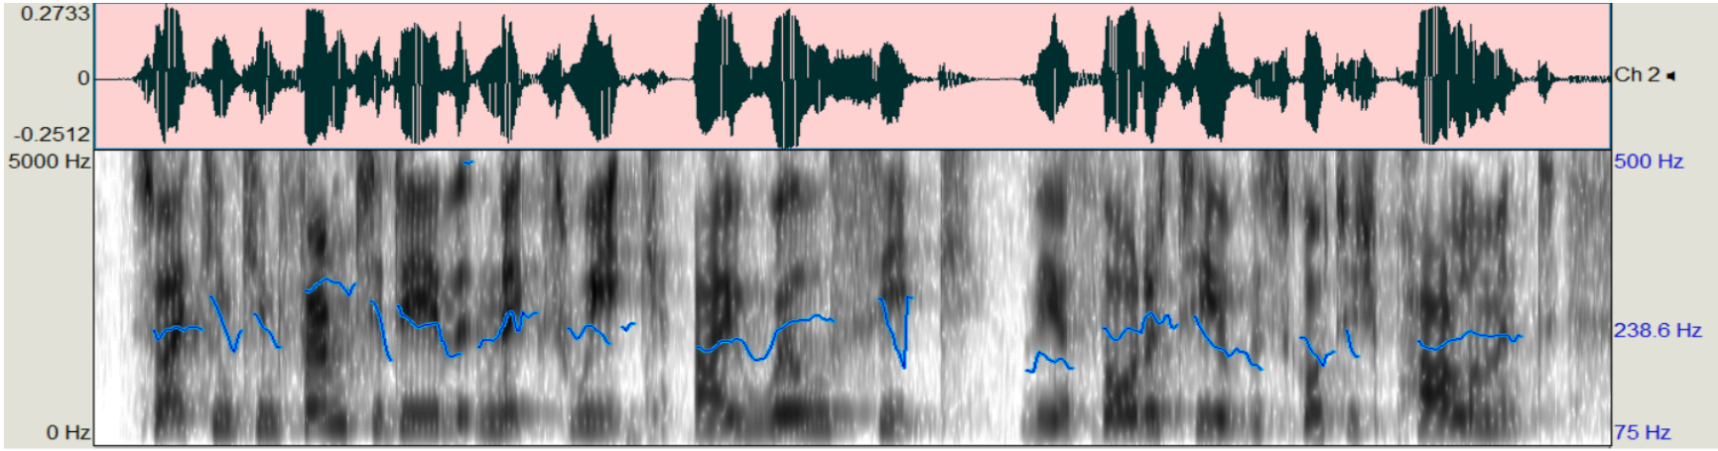
- 人耳是傅立叶分析器
- 模型：语音信号建模为局部广义平稳过程
- 表征映射：短时傅立叶变换，Mel 滤波器组
- 表征：从时域表征（波形）到时频域表征（频谱图）
- 作为深度学习的特征提取步骤





作为图像的声音

- 频谱图：关于时间和频率的二元函数
- 似图非图
  - 时间轴和频率轴非对称
  - 视觉对象只有覆盖无重叠，声音事件可重叠
- 计算机视觉方法迁移：卷积神经网络



判别式任务举例：语音识别

Multitask training data (680k hours)

English transcription

- 🗣️ "Ask not what your country can do for …"
- 📝 Ask not what your country can do for …

Any-to-English speech translation

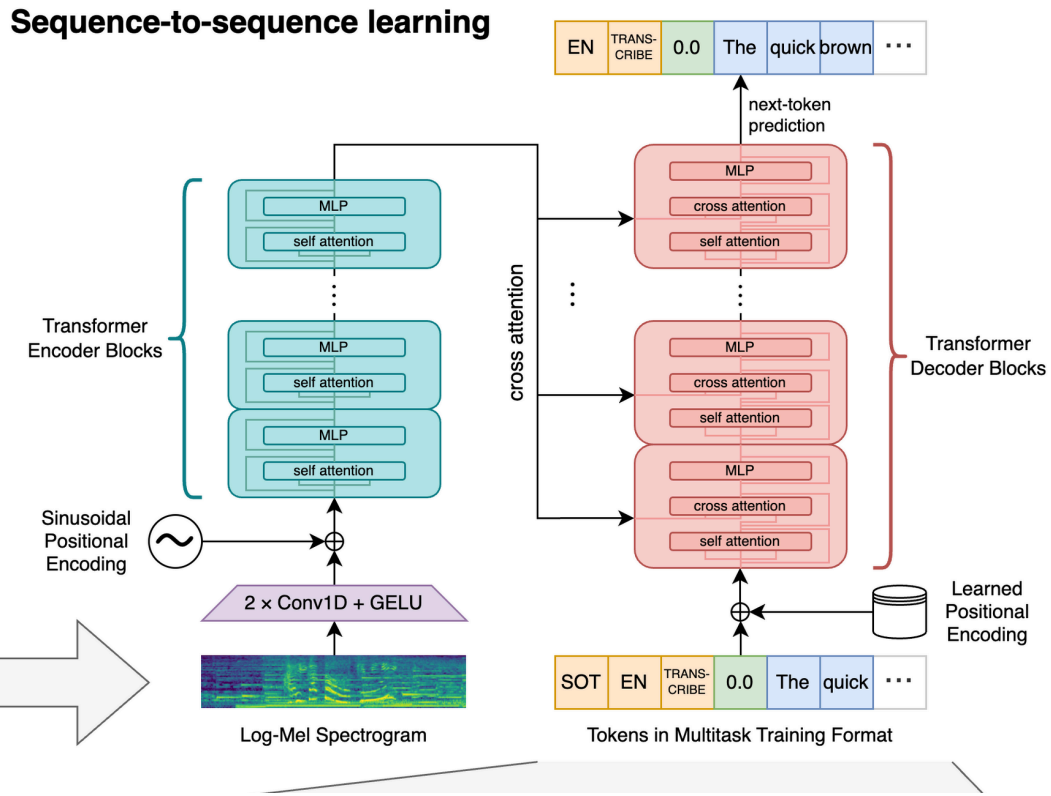
- 🗣️ "El rápido zorro marrón salta sobre …"
- 📝 The quick brown fox jumps over …

Non-English transcription

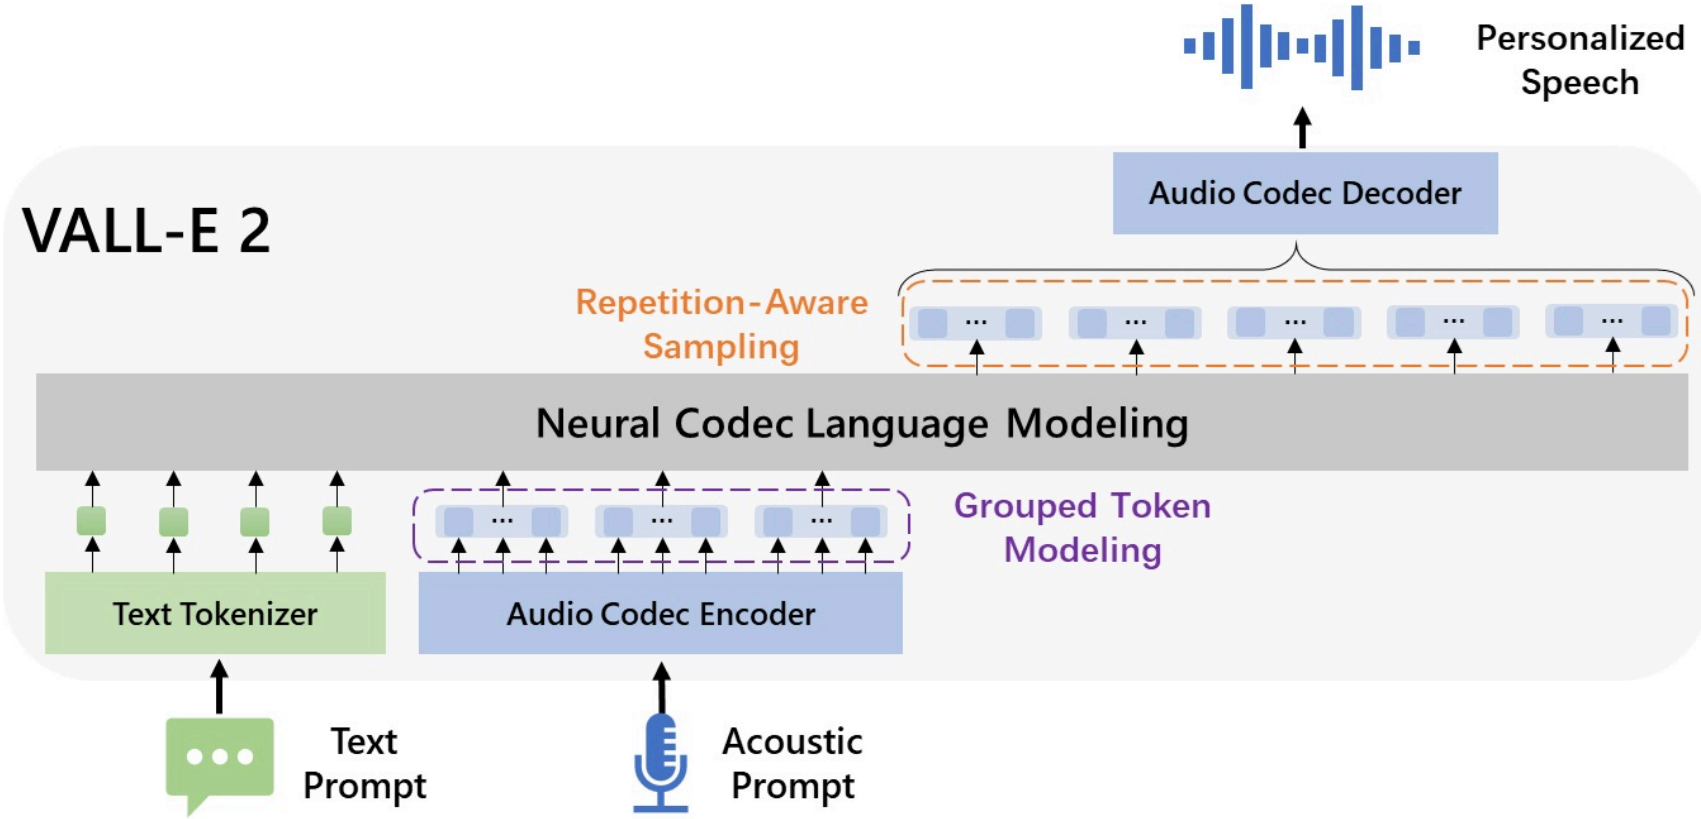
- 🗣️ "언덕 위에 올라 내려다보면 너무나 넓고 넓은 …"
- 📝 언덕 위에 올라 내려다보면 너무나 넓고 넓은 …

No speech

- 🔊 (background music playing)
- 📝 ∅

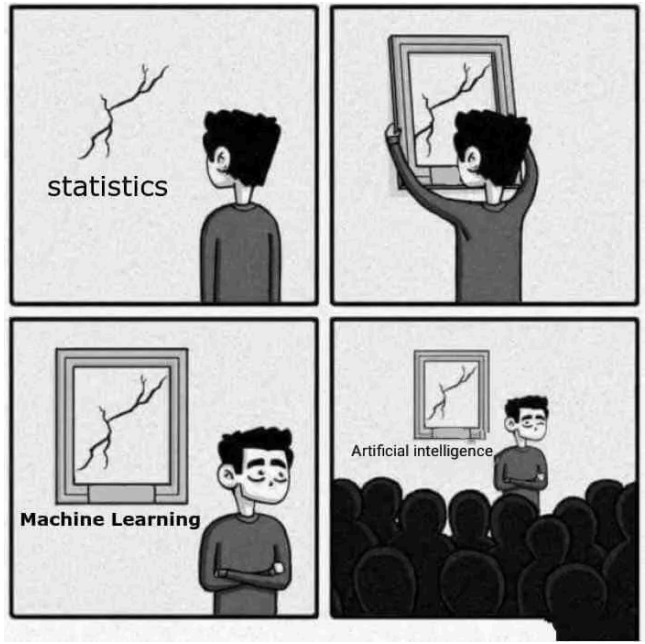


生成式任务举例：语音合成



感想

- 通用人工智能问题
- 涌现还是误认
- 新的物神
- AI 工具的使用体验
- 炒作和投机：
  - 混乱的术语
  - 社交媒体中的科研
  - 模型/测试造假
  - 指标与现实需要脱节
  - 头部公司互保



彩蛋

谢谢